
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа Прикладной Математики и Информатики
Кафедра интеллектуальных систем

Направление подготовки / специальность: 03.03.01 Прикладные математика и физика

Направленность (профиль) подготовки: Математическая физика, компьютерные технологии и
математическое моделирование в экономике

МУЛЬТИМОДАЛЬНАЯ АППРОКСИМАЦИЯ ДАННЫХ ФМРТ НА ОСНОВЕ АУДИОВИЗУАЛЬНЫХ СТИМУЛОВ

(бакалаврская работа)

Студент:

Герман Анастасия Яновна

(подпись студента)

Научный руководитель:

Грабовой Андрей Валериевич,
канд. физ.-мат. наук

(подпись научного руководителя)

Консультант (при наличии):

(подпись консультанта)

Москва 2026

Аннотация

Рассматривается мультимодальное обобщение линейной задачи прогнозирования фМРТ, в которой последовательность воксельных снимков восстанавливается одновременно по видео- и аудиопотоку натуралистичного аудиовизуального стимула. Подход развивается в три этапа возрастающей методологической сложности. Отправной точкой служит одномодальная базовая модель, предсказывающая BOLD-сигнал по мел-частотным кепстральным коэффициентам (MFCC) звуковой дорожки. Затем вводится мультимодальная модель на основе гребневой регрессии с раздельными поблочными штрафами (banded ridge), которая объединяет аудио-эмбединг со сжатым по размерности методом главных компонент (PCA) видеоэмбедингом и назначает каждой модальности отдельный коэффициент регуляризации, такой анализ выявляет пространственную неоднородность вкладов аудио и видео в BOLD-сигнал. Однако, наивная конкатенация переоценивает более высокоразмерный поток и смешивает относительные вклады двух модальностей, а сама модель ограничена архитектурной асимметрией между низкоразмерным аудиопредставлением, сконструированным вручную, и высокоразмерным предобученным видеопредставлением. Чтобы устранить эту асимметрию, MFCC-кодировщик заменяется самообучаемым речевым трансформером той же размерности, что и видеокодировщик, и предлагается повоксельная gated-модель: на каждой модальности независимо обучается гребневая регрессия, а два предсказания комбинируются через повоксельный скалярный гейт $\alpha_{ijk} \in [0,1]$. Оптимальный гейт выводится аналитически в замкнутой форме как наклон одномерной регрессии методом наименьших квадратов, усечённый на единичный отрезок $[0,1]$. Полученная модель проверяется на публичном датасете натуралистичной стимуляции ЭЭГ-фМРТ, где gated-модель устойчиво превосходит обе одномодальные базовые модели на каждом испытуемом.

Ключевые слова: функциональная магнитно-резонансная томография (фМРТ), BOLD-сигнал, мультимодальная регрессия, гребневая регрессия, повоксельный гейтинг.

Содержание

Обозначения и сокращения	4
1 Введение	5
2 Обзор литературы	7
3 Постановка задачи	9
4 Одномодальная аппроксимация	10
4.1 Повоксельная линейная регрессия	10
4.2 Эмпирический подбор задержки Δt	10
5 Вероятностная модель мультимодального гейта	12
5.1 Постановка	12
5.2 Совместная мультимодальная регрессия	13
5.3 Двумодальная порождающая модель и гейт	13
5.4 Оптимальность gated-оценки	14
5.5 Апостериор гейта	15
5.6 Распределение гейта по маске	17
6 Данные и предобработка	19
6.1 Набор данных	19
6.2 Предобработка	19
6.3 Признаковые представления модальностей	20
6.4 Маска мозга	20
7 Вычислительный эксперимент	21
7.1 Качество восстановления	21
7.2 Анализ весов	22
7.3 Оценка задержки Δt	23
7.4 Мультимодальная banded-ridge регрессия	24
7.5 Гейтовая мультимодальная модель	29
8 Заключение	37
Список литературы	38

Обозначения и сокращения

Сокращения

фМРТ	функциональная магнитно-резонансная томография
ЭЭГ	электроэнцефалография
BOLD	blood-oxygen-level dependent (сигнал)
MFCC	мел-частотные кепстральные коэффициенты
HuBERT	Hidden-Unit BERT, самообучаемый речевой трансформер
ViT	Vision Transformer
PCA	метод главных компонент
MSE	среднеквадратичная ошибка
ROI	область интереса (region of interest)
MAP	оценка апостериорного максимума
MMSE	минимум среднеквадратичной ошибки
MA(1)	скользящее среднее первого порядка
CGMM	цензурированная гауссова смесь

Основные обозначения

s_ℓ	воксельный снимок BOLD-сигнала в момент ℓ
$\Delta = s_\ell - s_{\ell-1}$	приращение BOLD-сигнала между соседними снимками
Δt	гемодинамическая задержка
X_v, X_a	признаковые матрицы видео- и аудиопотока
w_m	веса гребневой регрессии модальности m
λ_m	коэффициент регуляризации модальности m
$\sigma^2, \sigma_{w,m}^2$	дисперсии шума и априора весов
$\hat{\delta}_v, \hat{\delta}_a$	предсказания приращения по видео и аудио
$\alpha \in [0,1]$	повоксельный скалярный гейт (вес видео)
$m_\star, s_\star^2$	среднее и дисперсия апостериора гейта
τ	повоксельная стандартная ошибка оценки гейта
$\mathcal{M}$	маска мозга

1. Введение

Понимание того, как мозг воспринимает и обрабатывает внешние стимулы, — одна из центральных задач нейронаук. Ведущим неинвазивным инструментом её изучения является функциональная магнитно-резонансная томография (фМРТ), измеряющая гемодинамический отклик через BOLD-сигнал (blood oxygen level-dependent), который отражает локальные изменения уровня оксигенации крови, сопутствующие нейронной активности [1, 2, 3]. Изучение того, как именно внешний стимул отображается в активность мозга, важно не только само по себе. Количественная и интерпретируемая модель связи «стимул — отклик» приближает к пониманию принципов, по которым кора кодирует сенсорную информацию, и одновременно служит основой для прикладных направлений: ранней диагностики и мониторинга неврологических и психических расстройств, нейроинтерфейсов, восстанавливающих связь с внешним миром при утрате речи или движения, и методов реконструкции воспринимаемого по мозговой активности [4, 5, 6]. Прогресс в этих задачах напрямую зависит от того, насколько точно и интерпретируемо удаётся связать характеристики стимула с измеряемым сигналом, что и мотивирует разработку простых, хорошо интерпретируемых моделей такой связи.

Особый интерес представляет натуралистическая стимуляция, при которой испытуемому предъявляется не упрощённый изолированный стимул, а полноценный аудиовизуальный фильм. Такой режим ближе к естественному восприятию, но и существенно усложняет сопоставление стимула с мозговым откликом.

В настоящей работе рассматривается задача прогнозирования последовательности фМРТ-снимков по аудио- и видеопотоку предъявляемого стимула. Каждый из потоков представляется последовательностью векторных признаков, а для каждого вокселя строится отдельная линейная модель, предсказывающая приращение BOLD-сигнала между соседними снимками по короткому окну этих признаков.

Целью работы является установление и количественное описание зависимости между аудиовизуальным стимулом и вызванной им последовательностью фМРТ-снимков с помощью простой и интерпретируемой повоксельной линейной модели. Достижение этой цели выстроено как последовательность экспериментов возрастающей сложности, описанная далее.

Отправной точкой служит одномодальная аудио-модель. Для каждого вокселя строится отдельная линейная модель, предсказывающая приращение BOLD-сигнала между соседними снимками по короткому окну признаков стимула. Такой повоксельный подход хорошо интерпретируется и не требует больших вычислительных ресурсов, в отличие от крупных нелинейных моделей [7, 8, 9]. Существенным фактором является запаздывание Δt между предъявлением стимула и гемодинамическим откликом [10, 11], а также собственный шум фМРТ [12, 13]: при оценке оптимального Δt по всему мозгу кривая ошибки оказывается зашумлённой и многомодальной, тогда как при ограничении области до слуховой коры выделяется единственный глобальный минимум, что мотивирует использование маски мозга.

Переход от одной модальности к двум нетривиален. Наивная конкатенация аудио и видео признаков переоценивает более высокоразмерный поток и смешивает относительные вклады модальностей. Гребневая регрессия с отдельными поблочными штрафами позволяет

назначить каждому потоку свой коэффициент регуляризации [14], но этот коэффициент остаётся глобальным — единым для всего мозга — и потому не способен в каждом вокселе по-разному балансировать зрительный и слуховой вклад, тогда как именно пространственная неоднородность этих вкладов представляет наибольший интерес.

Чтобы преодолеть это ограничение, предлагается повоксельная gated-модель: на каждой модальности независимо обучается своя гребневая регрессия, после чего два предсказания комбинируются в каждом вокселе через скалярный гейт $\alpha_{ijk} \in [0,1]$. Чтобы устранить асимметрию между низкоразмерным рукотворным аудиопредставлением и высокоразмерным предобученным видеопредставлением, MFCC-кодировщик заменяется самообучаемым речевым трансформером той же размерности, что и видеокодировщик [15, 16]. Оптимальный гейт выводится аналитически в замкнутой форме как наклон одномерной регрессии методом наименьших квадратов, усечённый на отрезок $[0,1]$. Модель проверяется на открытом датасете натуралистической стимуляции ЭЭГ–фМРТ [17], а её превосходство над обеими одномодальными базовыми моделями подтверждается статистически на каждом испытуемом [18].

Таким образом, вклад работы состоит в следующем. Во-первых, выстроена последовательность из трёх моделей возрастающей сложности: одномодальной аудио-базовой, мультимодальной banded ridge и повоксельной gated-модели, позволяющая проследить, как и где видео дополняет аудио при восстановлении BOLD-сигнала. Во-вторых, для гейта получено замкнутое аналитическое выражение, не требующее итеративной оптимизации и дающее интерпретируемую повоксельную карту вклада модальностей. В-третьих, на публичном датасете показано устойчивое улучшение качества прогноза относительно обеих одномодальных моделей с подтверждением статистической значимости.

Работа построена следующим образом. В разделе 3 приводится общая постановка задачи прогнозирования приращений BOLD-сигнала. В разделе 4 строится одномодальная аппроксимация по аудиопотоку, включающая повоксельную линейную регрессию и оценку гемодинамического запаздывания Δt . В разделе 5 выводится вероятностная модель мультимодального гейта, в которую как базовый метод входит совместная регрессия banded ridge, доказывається оптимальность гейтовой оценки и анализируется распределение гейта по маске. В разделе 6 описываются набор данных ЭЭГ–фМРТ, предобработка, признаковые представления модальностей и маска мозга. В разделе 7 проводится вычислительный эксперимент, в котором banded ridge и гейтовая модель сравниваются между собой и с одномодальными базлайнами. В разделе 8 подводятся итоги.

2. Обзор литературы

Моделирование фМРТ-данных осложнено рядом методических трудностей. Значительную часть энергии мозг расходует на непрерывную фоновую активность сети пассивного режима — так называемую «тёмную энергию» мозга, которая накладывается на вызванный стимулом сигнал [19]. Процедуры шумоподавления, удаляющие компоненты, связанные с движением головы и дыханием, способны вместе с шумом устранять и осмысленные паттерны активности, что требует осторожных и сбалансированных методов очистки [12]. При этом спонтанные колебания BOLD-сигнала различаются между областями мозга и связаны с тем, как эти области физически соединены [20], поэтому глобальные модели шума плохо отражают локальные различия. Для выделения устойчивых структур в таких данных применяются в том числе топологические методы, в частности кубическая персистентность [21, 22]. Дополнительно картину усложняют гемодинамическое запаздывание и вариабельность функции отклика [10, 11].

Параллельно интеграция фМРТ с методами машинного обучения существенно продвинула декодирование слуховых стимулов и реконструкцию нейронного отклика. Задача обычно ставится как кодирование или декодирование [7], причём воксельные кодирующие модели выявляют, например, семантические карты, покрывающие кору больших полушарий [8]. Современные подходы на основе глубокого обучения предсказывают семантику звуков по мозговой активности и восстанавливают характеристики стимула [4, 5, 6], а задаче-оптимизированные нейронные сети воспроизводят поведение слуховой системы и обнаруживают иерархическую организацию слуховой коры [23]. Эти модели достигают высокого качества, однако требуют больших объёмов данных и вычислений и хуже поддаются интерпретации.

В противоположность ресурсоёмким нейросетевым моделям развиваются простые и интерпретируемые подходы. Байесовские обобщённые линейные модели допускают разный уровень шума и временные зависимости в разных областях и подстраиваются под каждый воксель, улучшая выделение истинного сигнала [24, 25]. Накопленное знание о слуховой коре — её тонотопическая и анатомо-функциональная организация и кодирование звука на нескольких спектрально-временных масштабах [26, 27, 28, 29, 30] — подсказывает, какие признаки стимула информативны. Звуковой поток компактно описывается мел-частотными кепстральными коэффициентами [31, 32], обучаемой альтернативой им служат самообучаемые речевые трансформеры [15], а зрительный поток представляется эмбедингами трансформеров изображений [16]. Для совместного кодирования нескольких пространств признаков применяется гребневая регрессия с отдельными поблочными штрафами [14].

Большинство перечисленных работ рассматривает одну модальность — либо звук, либо изображение. Непосредственным предшественником настоящей работы является линейный повоксельный подход [9], прогнозирующий последовательность фМРТ-снимков по видеоряду стимула, а аналогичная одномодальная постановка для аудиопотока составляет первый этап настоящей работы. Совместное использование обеих модальностей в задаче прогнозирования исследовано слабее. Наивная конкатенация признаков переоценивает более высокоразмерный поток, а гребневая регрессия с отдельными штрафами балансирует вклады модальностей

лишь глобально, единым коэффициентом на весь мозг. Настоящая работа развивает линейный подход на мультимодальный случай и вводит повоксельный гейт α_{ijk} , позволяющий локально, в каждом вокселе, регулировать соотношение слухового и зрительного вкладов.

3. Постановка задачи

Пусть испытуемому предъявляется аудиовизуальный стимул длительности t , а в ходе предъявления регистрируется последовательность фМРТ-снимков

$$S = [s_1, \dots, s_{\mu t}], \quad s_\ell \in \mathbb{R}^{X \times Y \times Z}, \quad (1)$$

где μ — частота сканирования фМРТ, а X, Y, Z — размеры объёма по трём осям. Отдельный воксель снимка обозначается s_{ijk}^ℓ .

Прогнозируемой величиной является не сам снимок, а его приращение между двумя соседними сканированиями

$$\delta_\ell = s_\ell - s_{\ell-1} = [\delta_{ijk}^\ell] \in \mathbb{R}^{X \times Y \times Z}, \quad \ell = 2, \dots, \mu t. \quad (2)$$

Переход к приращениям убирает медленный тренд и постоянную составляющую BOLD-сигнала и оставляет именно ту динамику, которая может быть связана с изменением стимула.

Стимул на каждом шаге описывается векторным признаком $\mathbf{z}_\ell \in \mathbb{R}^d$, конкретный вид которого уточняется в каждом из последующих разделов: в одномодальном случае это признаки аудиопотока, в мультимодальном — совместное представление аудио- и видеопотока. Поскольку частоты стимула и фМРТ различны, ℓ -му снимку сопоставляется индекс признака

$$k_\ell = \frac{\ell}{\mu} \nu, \quad (3)$$

где ν — частота дискретизации признаков стимула.

Гемодинамический отклик запаздывает относительно стимула, поэтому вводится сдвиг Δt , и приращение δ_ℓ предсказывается по короткому окну признаков, предшествующему моменту $k_\ell - \nu \Delta t$:

$$f(\mathbf{z}_{k_\ell - \nu \Delta t - g}, \dots, \mathbf{z}_{k_\ell - \nu \Delta t}) = \delta_\ell, \quad (4)$$

где g — размер окна. С учётом сдвига число обучающих пар равно $N = \mu(t - \Delta t)$.

4. Одномодальная аппроксимация

Отправной точкой служит одномодальная модель, восстанавливающая последовательность фМРТ-снимков только по аудиопотоку стимула. Она задаёт базовое качество прогноза для сравнения с мультимодальной моделью, и на ней же оцениваются два общих для всей работы элемента: гемодинамическая задержка Δt и маска мозга.

4.1. Повоксельная линейная регрессия

Задача решается повоксельно: для каждого вокселя (i, j, k) строится отдельная линейная модель, предсказывающая скалярный временной ряд приращений δ_{ijk}^ℓ по матрице признаков $X \in \mathbb{R}^{N \times d}$, составленной из окон (4). Обозначив целевой ряд вокселя $Y_{ijk} \in \mathbb{R}^N$, примем линейную модель

$$Y_{ijk} = X\theta_{ijk} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I), \quad (5)$$

где $\theta_{ijk} \in \mathbb{R}^d$ — вектор коэффициентов вокселя. Веса оцениваются методом максимального правдоподобия, что при гауссовом шуме (5) равносильно методу наименьших квадратов:

$$\hat{\theta}_{ijk} = \arg \max_{\theta} p(Y_{ijk} | X, \theta) = \arg \min_{\theta} \|Y_{ijk} - X\theta\|^2 = (X^\top X)^{-1} X^\top Y_{ijk}. \quad (6)$$

Признаками служат мел-частотные кепстральные коэффициенты (MFCC) невысокой размерности ($d = 15$), а число снимков N значительно превосходит d , поэтому матрица $X^\top X$ невырождена и дополнительная регуляризация не требуется.

Качество прогноза оценивается среднеквадратичной ошибкой (MSE) между предсказанными и истинными приращениями, усреднённой по вокселям внутри маски мозга. Маска выделяет воксели, содержащие мозговую ткань, и исключает фон, на котором сигнал неинформативен; способ её построения описан в разделе 6.4. Здесь и далее σ^2 обозначает дисперсию шума рассматриваемой модели; для разных моделей (одномодальной и мультимодальной) эти величины, вообще говоря, различны и не предполагаются равными.

4.2. Эмпирический подбор задержки Δt

Гемодинамическая задержка Δt между стимулом и BOLD-откликом не выводится из модели, а является гиперпараметром, задающим сдвиг признаков относительно снимка в (4). Её значение подбирается эмпирически: для каждого кандидата Δt из заданной сетки признаки сдвигаются на Δt , по ним обучается повоксельная модель (6) и вычисляется ошибка на отложенной части; берётся значение, минимизирующее MSE,

$$\hat{\Delta t} = \arg \min_{\Delta t} \text{MSE}(\Delta t). \quad (7)$$

Подбор проводится независимо для каждого испытуемого, поскольку гемодинамическая задержка варьируется между пациентами. При оценке Δt по всему мозгу кривая ошибки зашумлена и многомодальна, а при ограничении усреднения на маску мозга (преимущественно слуховую кору) выделяется единственный глобальный минимум, что и мотивирует

использование маски при оценке задержки.

5. Вероятностная модель мультимодального гейта

5.1. Постановка

Зафиксируем воксель (i, j, k) и далее опускаем его индекс. Целевой величиной служит приращение BOLD-сигнала между соседними снимками, $\Delta = s_\ell - s_{\ell-1} \in \mathbb{R}^{N-1}$, рассматриваемое как вектор по временной оси. Видеопоток и аудиопоток задают признаковые матрицы $X_v \in \mathbb{R}^{(N-1) \times d_v}$ и $X_a \in \mathbb{R}^{(N-1) \times d_a}$.

Признаковые матрицы X_v и X_a построены при фиксированной гемодинамической задержке Δt из раздела 3: их строки отвечают окнам признаков, сдвинутым на Δt относительно момента снимка согласно (4). Задержка Δt оценивается отдельно (раздел 4.2) и далее считается зафиксированной, поэтому в выкладках гейта она не варьируется.

Для каждой модальности $m \in \{v, a\}$ примем, что приращение порождается линейной моделью с гауссовым шумом

$$\Delta = X_m w_m + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I), \quad (8)$$

а веса имеют гауссово априорное распределение

$$w_m \sim \mathcal{N}(0, \sigma_{w,m}^2 I)$$

что эквивалентно $\Delta \mid X_m, w_m \sim \mathcal{N}(X_m w_m, \sigma^2 I)$.

Найдём апостериорное распределение весов. По формуле Байеса $p(w_m \mid X_m, \Delta) \propto p(\Delta \mid X_m, w_m) p(w_m)$, и в логарифме произведение переходит в сумму,

$$\log p(w_m \mid X_m, \Delta) = -\frac{1}{2\sigma^2} \|\Delta - X_m w_m\|^2 - \frac{1}{2\sigma_{w,m}^2} \|w_m\|^2 + \text{const}. \quad (9)$$

Первое слагаемое — логарифм гауссова правдоподобия, второе — логарифм гауссова априора, постоянные нормировки собраны в const. Точка максимума апостериора (МАР-оценка) совпадает с минимумом противоположной величины, то есть с решением задачи гребневой регрессии

$$\bar{w}_m = \arg \min_w \|\Delta - X_m w\|^2 + \lambda_m \|w\|^2, \quad \lambda_m = \frac{\sigma^2}{\sigma_{w,m}^2}. \quad (10)$$

Приравнивая градиент к нулю,

$$\nabla_w \left(\|\Delta - X_m w\|^2 + \lambda_m \|w\|^2 \right) = -2X_m^\top (\Delta - X_m w) + 2\lambda_m w = 0,$$

получаем нормальное уравнение $(X_m^\top X_m + \lambda_m I) w = X_m^\top \Delta$, откуда

$$\bar{w}_m = (X_m^\top X_m + \lambda_m I)^{-1} X_m^\top \Delta. \quad (11)$$

Таким образом, гребневая регрессия — это МАР-оценка весов при гауссовом априоре, а параметр регуляризации λ_m есть отношение дисперсии шума к дисперсии априора. Предсказание

приращения по каждой модальности

$$\widehat{\delta}_m := X_m \bar{w}_m \quad (12)$$

есть гауссова случайная величина, и (8)–(12) задают две независимые байесовские регрессии, по одной на модальность.

5.2. Совместная мультимодальная регрессия

Прежде чем переходить к гейту, опишем мультимодальный базовый метод, в котором обе модальности используются совместно. Признаки склеиваются в общую матрицу $X = [X_v \ X_a] \in \mathbb{R}^{(N-1) \times (d_v + d_a)}$, а веса — в общий вектор $w = (w_v^\top, w_a^\top)^\top$. На него задаётся блочно-гауссов априор с отдельной дисперсией на каждую модальность,

$$w \sim \mathcal{N}(0, \text{diag}(\sigma_{w,v}^2 I_{d_v}, \sigma_{w,a}^2 I_{d_a})), \quad \Delta = Xw + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I). \quad (13)$$

МАР-оценка весов при таком априоре — это регрессия с раздельными штрафами по блокам (banded ridge [14]):

$$\bar{w} = \arg \min_w \|\Delta - X_v w_v - X_a w_a\|^2 + \lambda_v \|w_v\|^2 + \lambda_a \|w_a\|^2 = (X^\top X + \Lambda)^{-1} X^\top \Delta, \quad (14)$$

где $\Lambda = \text{diag}(\lambda_v I_{d_v}, \lambda_a I_{d_a})$ и $\lambda_m = \sigma^2 / \sigma_{w,m}^2$, как и в (10). Предсказание приращения — совместное,

$$\widehat{\delta} = X \bar{w} = X_v \bar{w}_v + X_a \bar{w}_a. \quad (15)$$

В отличие от раздельных регрессий (11), где каждая модальность приближает Δ независимо, здесь модальности связаны через перекрёстный блок $X_v^\top X_a$ матрицы $X^\top X$ и подгоняются совместно, при этом блочный штраф позволяет каждой модальности сохранить свой коэффициент регуляризации λ_m . Модель (14) служит мультимодальным базовым методом, с которым в разделе 7 сравнивается гейтовая модель.

5.3. Двумодальная порождающая модель и гейт

Истинное приращение моделируется выпуклой комбинацией двух предсказаний с повоксельным скалярным гейтом $\alpha \in [0, 1]$ и гауссовым шумом, а сам гейт снабжается гауссовым априором,

$$\Delta = \alpha \widehat{\delta}_v + (1 - \alpha) \widehat{\delta}_a + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I), \quad \alpha \sim \mathcal{N}(m_0, s_0^2). \quad (16)$$

Здесь $\alpha \rightarrow 1$ выбирает видео, $\alpha \rightarrow 0$ — аудио, а обе модальности входят явно и симметрично. Введём две производные величины: разность предсказаний модальностей и остаток аудио-модели,

$$d := \widehat{\delta}_v - \widehat{\delta}_a, \quad r := \Delta - \widehat{\delta}_a. \quad (17)$$

Вектор d задаёт направление, вдоль которого расходятся предсказания модальностей, а r — часть приращения, не объяснённую аудио-моделью. Ключевое тождество, которым мы будем

пользоваться повсюду: подмешивание видео сдвигает предсказание вдоль d ,

$$\alpha \widehat{\delta}_v + (1 - \alpha) \widehat{\delta}_a = \widehat{\delta}_a + \alpha (\widehat{\delta}_v - \widehat{\delta}_a) = \widehat{\delta}_a + \alpha d, \quad (18)$$

откуда ошибка комбинации равна $\Delta - (\widehat{\delta}_a + \alpha d) = r - \alpha d$.

5.4. Оптимальность gated-оценки

Теорема 1 (gated как проекция двух модальностей). Пусть $\|d\| > 0$, $\alpha^* = \langle d, r \rangle / \|d\|^2$, и $\widehat{\delta}(\alpha) = \alpha \widehat{\delta}_v + (1 - \alpha) \widehat{\delta}_a$. Тогда

1. (аффинный случай) α^* минимизирует квадратичную ошибку по всем $\alpha \in \mathbb{R}$, а $\widehat{\delta}(\alpha^*)$ есть ортогональная проекция Δ на прямую $\mathcal{L} = \{\widehat{\delta}_a + \beta d : \beta \in \mathbb{R}\}$:

$$\alpha^* = \arg \min_{\alpha \in \mathbb{R}} \|\Delta - \widehat{\delta}(\alpha)\|^2, \quad \langle d, r - \alpha^* d \rangle = 0; \quad (19)$$

2. (выпуклый случай) минимизатор на отрезке $[0, 1]$ есть $\widehat{\alpha} = \text{clip}(\alpha^*, 0, 1)$;

3. (величина выигрыша) при $0 < \widehat{\alpha} < 1$

$$\|\Delta - \widehat{\delta}(\widehat{\alpha})\|^2 = \|r\|^2 (1 - \rho^2), \quad \rho = \frac{\langle d, r \rangle}{\|d\| \|r\|}. \quad (20)$$

Никакая комбинация двух модальностей — ни выпуклая, ни аффинная — не даёт меньшей квадратичной ошибки, чем gated.

Доказательство. Шаг 1 (сведение к одномерной задаче). По тождеству (18) ошибка комбинации зависит от α только через $r - \alpha d$, поэтому

$$g(\alpha) := \|\Delta - \widehat{\delta}(\alpha)\|^2 = \|r - \alpha d\|^2 = \|r\|^2 - 2\alpha \langle d, r \rangle + \alpha^2 \|d\|^2. \quad (21)$$

Шаг 2 (минимум). Функция g — квадратичная по α с положительным старшим коэффициентом $\|d\|^2 > 0$, значит строго выпукла и имеет единственный минимум. Из условия стационарности

$$g'(\alpha) = -2\langle d, r \rangle + 2\alpha \|d\|^2 = 0 \implies \alpha^* = \frac{\langle d, r \rangle}{\|d\|^2},$$

что доказывает левую часть (19). *Шаг 3 (ортогональность).* Подставив α^* , проверим, что остаток перпендикулярен d :

$$\langle d, r - \alpha^* d \rangle = \langle d, r \rangle - \alpha^* \|d\|^2 = \langle d, r \rangle - \frac{\langle d, r \rangle}{\|d\|^2} \|d\|^2 = 0.$$

Равенство нулю означает, что $\widehat{\delta}(\alpha^*) = \widehat{\delta}_a + \alpha^* d$ есть ортогональная проекция Δ на прямую $\mathcal{L}$. *Шаг 4 (усечение).* На отрезке $[0, 1]$ минимум строго выпуклой функции достигается в проекции безусловного минимума на отрезок, то есть в $\widehat{\alpha} = \text{clip}(\alpha^*, 0, 1)$. *Шаг 5 (выигрыш).*

Подставляя α^* в (21),

$$g(\alpha^*) = \|r\|^2 - \frac{\langle d, r \rangle^2}{\|d\|^2} = \|r\|^2 \left(1 - \frac{\langle d, r \rangle^2}{\|d\|^2 \|r\|^2} \right) = \|r\|^2 (1 - \rho^2),$$

что даёт (20). Минимальность $g(\hat{\alpha})$ на $[0,1]$ влечёт, что gated не уступает ни одной комбинации двух модальностей. $\square$

Замечание 1 (Аффинный против выпуклого). *Безусловный оптимум α^* отвечает проекции на всю прямую $\mathcal{L}$, а ограничение $\alpha \in [0,1]$ выражает требование выпуклой комбинации и реализуется усечением, которое само есть метрическая проекция на $[0,1]$. Оба варианта оптимальны в своём классе.*

Теорема 2 (Гарантия неухудшения и вырождение). *Пусть $L_a = \|r\|^2$ и $L_v = \|r - d\|^2$ — ошибки аудио- и видео-моделей. Тогда для gated-оценки $\hat{\alpha}$ из Теоремы 1*

1. $g(\hat{\alpha}) \leq \min\{L_a, L_v\}$, и усреднение по любому множеству вокселей, в частности по маске $\mathcal{M}$, сохраняет неравенство;
2. $\hat{\alpha} = 0 \iff \langle d, r \rangle \leq 0$, и $\hat{\alpha} = 1 \iff \langle d, r \rangle \geq \|d\|^2$.

Доказательство. Пункт 1. Значения $\alpha = 0$ и $\alpha = 1$ лежат в $[0,1]$ и дают $g(0) = \|r\|^2 = L_a$ и $g(1) = \|r - d\|^2 = L_v$. Поскольку $\hat{\alpha}$ минимизирует g на $[0,1]$,

$$g(\hat{\alpha}) \leq g(0) = L_a, \quad g(\hat{\alpha}) \leq g(1) = L_v \implies g(\hat{\alpha}) \leq \min\{L_a, L_v\}.$$

Эти неравенства поточечны по вокселям; усреднение левой и правой частей по маске сохраняет знак $\leq$. Пункт 2. Знак производной на концах отрезка определяет положение минимума. Из $g'(\alpha) = 2(\alpha\|d\|^2 - \langle d, r \rangle)$ получаем $g'(0) = -2\langle d, r \rangle$: если $\langle d, r \rangle \leq 0$, то $g'(0) \geq 0$, функция не убывает от нуля и минимум на $[0,1]$ достигается в 0. Аналогично $g'(1) = 2(\|d\|^2 - \langle d, r \rangle)$: при $\langle d, r \rangle \geq \|d\|^2$ имеем $g'(1) \leq 0$, функция убывает вплоть до 1 и минимум достигается в 1. $\square$

5.5. Апостериор гейта

Лемма 3 (Сопряжённость гейта). *В модели (16), эквивалентной одномерной регрессии $r = \alpha d + \varepsilon$ $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ и $\alpha \sim \mathcal{N}(m_0, s_0^2)$, апостериор гейта гауссов,*

$$\alpha \mid d, r \sim \mathcal{N}(m_*, s_*^2), \quad s_*^2 = \left(\frac{\|d\|^2}{\sigma^2} + \frac{1}{s_0^2} \right)^{-1}, \quad m_* = s_*^2 \left(\frac{\langle d, r \rangle}{\sigma^2} + \frac{m_0}{s_0^2} \right). \quad (22)$$

Доказательство. Шаг 1 (логарифм апостериора). По формуле Байеса $p(\alpha \mid d, r) \propto p(r \mid \alpha, d) p(\alpha)$, и в логарифме

$$\log p(\alpha \mid d, r) = -\frac{1}{2\sigma^2} \|r - \alpha d\|^2 - \frac{1}{2s_0^2} (\alpha - m_0)^2 + \text{const.}$$

Шаг 2 (раскрытие квадратов). Раскроем оба квадрата по α :

$$\|r - \alpha d\|^2 = \|r\|^2 - 2\alpha \langle d, r \rangle + \alpha^2 \|d\|^2, \quad (\alpha - m_0)^2 = \alpha^2 - 2\alpha m_0 + m_0^2.$$

Подставляя и группируя по степеням α , с точностью до постоянной

$$\log p(\alpha \mid d, r) = -\frac{1}{2} \underbrace{\left(\frac{\|d\|^2}{\sigma^2} + \frac{1}{s_0^2} \right)}_{=:A} \alpha^2 + \underbrace{\left(\frac{\langle d, r \rangle}{\sigma^2} + \frac{m_0}{s_0^2} \right)}_{=:B} \alpha + \text{const.}$$

Шаг 3 (сравнение с гауссом). Логарифм плотности $\mathcal{N}(m_*, s_*^2)$ с точностью до постоянной равен $-\frac{1}{2s_*^2} \alpha^2 + \frac{m_*}{s_*^2} \alpha$. Приравнивая коэффициенты при α^2 и при α ,

$$\frac{1}{s_*^2} = A \implies s_*^2 = \frac{1}{A}, \quad \frac{m_*}{s_*^2} = B \implies m_* = s_*^2 B,$$

что после подстановки A, B даёт (22). Так как логарифм апостериора квадратичен по α , апостериор гауссов. $\square$

Теорема 4 (Апостериор гейта и его пределы). *В условиях Леммы 3*

1. (неинформативный априор) при $s_0 \rightarrow \infty$

$$m_* \rightarrow \frac{\langle d, r \rangle}{\|d\|^2} = \alpha^*, \quad s_*^2 \rightarrow \tau^2 := \frac{\sigma^2}{\|d\|^2}; \quad (23)$$

2. (коррелированный шум) если $\varepsilon \sim \mathcal{N}(0, \Sigma)$, то при $s_0 \rightarrow \infty$ дисперсия оценки α^* равна

$$\tau^2 = \frac{d^\top \Sigma d}{\|d\|^4}; \quad (24)$$

3. (регуляризация гейта) при конечном s_0 величина m_* есть выпуклая комбинация α^* и m_0 , и при $\|d\| \rightarrow 0$ выполнено $m_* \rightarrow m_0$, $s_*^2 \rightarrow s_0^2$.

Доказательство. Пункт 1. В (22) устремим $s_0 \rightarrow \infty$, то есть $1/s_0^2 \rightarrow 0$. Тогда $A \rightarrow \|d\|^2/\sigma^2$ и $B \rightarrow \langle d, r \rangle/\sigma^2$, откуда

$$m_* = \frac{B}{A} \rightarrow \frac{\langle d, r \rangle/\sigma^2}{\|d\|^2/\sigma^2} = \frac{\langle d, r \rangle}{\|d\|^2} = \alpha^*, \quad s_*^2 = \frac{1}{A} \rightarrow \frac{\sigma^2}{\|d\|^2}.$$

Пункт 2. При $s_0 \rightarrow \infty$ оценка равна $\alpha^* = \langle d, r \rangle/\|d\|^2$. Подставляя $r = \alpha d + \varepsilon$,

$$\alpha^* = \frac{\langle d, \alpha d + \varepsilon \rangle}{\|d\|^2} = \alpha + \frac{\langle d, \varepsilon \rangle}{\|d\|^2},$$

так что случайна лишь добавка $\langle d, \varepsilon \rangle/\|d\|^2$. Её дисперсия

$$\text{Var}(\alpha^*) = \frac{\text{Var}(\langle d, \varepsilon \rangle)}{\|d\|^4} = \frac{d^\top \text{Cov}(\varepsilon) d}{\|d\|^4} = \frac{d^\top \Sigma d}{\|d\|^4}.$$

Пункт 3. Запишем среднее как взвешенное с $a = \|d\|^2/\sigma^2$, $b = 1/s_0^2$:

$$m_* = \frac{B}{A} = \frac{a \alpha^* + b m_0}{a + b} = \frac{a}{a + b} \alpha^* + \frac{b}{a + b} m_0.$$

При $\|d\| \rightarrow 0$ имеем $a \rightarrow 0$, поэтому вес данных $a/(a+b) \rightarrow 0$, откуда $m_\star \rightarrow m_0$ и $s_\star^2 = 1/(a+b) \rightarrow 1/b = s_0^2$. $\square$

Следствие 5 (MMSE-оптимальность). *Апостериорное среднее $m_\star = \mathbb{E}[\alpha \mid d, r]$ минимизирует среднеквадратичную ошибку: для любой оценки $\tilde{\alpha}(d, r)$*

$$\mathbb{E}[(\alpha - m_\star)^2 \mid d, r] \leq \mathbb{E}[(\alpha - \tilde{\alpha})^2 \mid d, r]. \quad (25)$$

При $s_0 \rightarrow \infty$ имеем $m_\star \rightarrow \alpha^*$, поэтому *gated-оценка есть усечённый предел MMSE-оптимальной оценки гейта.*

Доказательство. Добавим и вычтем $m_\star$ и раскроем квадрат:

$$\mathbb{E}[(\alpha - \tilde{\alpha})^2 \mid d, r] = \mathbb{E}[(\alpha - m_\star)^2 \mid d, r] + 2(m_\star - \tilde{\alpha}) \mathbb{E}[\alpha - m_\star \mid d, r] + (m_\star - \tilde{\alpha})^2.$$

Средний член равен нулю, так как $\mathbb{E}[\alpha \mid d, r] = m_\star$, а $(m_\star - \tilde{\alpha})$ при фиксированных данных постоянна. Остаётся

$$\mathbb{E}[(\alpha - \tilde{\alpha})^2 \mid d, r] = \mathbb{E}[(\alpha - m_\star)^2 \mid d, r] + (m_\star - \tilde{\alpha})^2 \geq \mathbb{E}[(\alpha - m_\star)^2 \mid d, r],$$

с равенством при $\tilde{\alpha} = m_\star$. Предел — из (23). $\square$

5.6. Распределение гейта по маске

Следствие 6 (МА(1)-поправка для разностной постановки). *Для разностной цели $\Delta = s_\ell - s_{\ell-1}$ шум обладает структурой скользящего среднего первого порядка МА(1), и дисперсия (24) принимает вид*

$$\tau^2 = \frac{\sigma^2}{\|d\|^2} (1 + 2\rho_1 r_d), \quad r_d = \frac{\sum_t d_t d_{t+1}}{\sum_t d_t^2}, \quad (26)$$

где ρ_1 — автокорреляция шума на лаге 1, а r_d — автокорреляция ряда d на лаге 1. При $\rho_1 = 0$ формула сводится к белой $\tau^2 = \sigma^2 / \|d\|^2$.

Доказательство. Ковариация МА(1)-шума трёхдиагональна: $\Sigma_{tt} = \sigma^2$, $\Sigma_{t, t\pm 1} = \rho_1 \sigma^2$, прочие элементы нули. Тогда квадратичная форма в числителе (24) раскрывается как

$$d^\top \Sigma d = \sigma^2 \sum_t d_t^2 + 2\rho_1 \sigma^2 \sum_t d_t d_{t+1} = \sigma^2 \|d\|^2 \left(1 + 2\rho_1 \frac{\sum_t d_t d_{t+1}}{\|d\|^2} \right) = \sigma^2 \|d\|^2 (1 + 2\rho_1 r_d),$$

где множитель 2 возникает из симметрии двух внедиагональных вкладов $(t, t+1)$ и $(t+1, t)$. Деление на $\|d\|^4$ даёт (26). $\square$

Следствие 7 (Усечение и цензурированная смесь). *Поскольку $\alpha \in [0, 1]$, апостериор (22) есть усечённый на $[0, 1]$ гаусс с точечными массами на границах,*

$$p(\alpha \mid d, r) = \Phi\left(\frac{-m_\star}{s_\star}\right) \delta_{\{0\}} + \Phi\left(\frac{m_\star - 1}{s_\star}\right) \delta_{\{1\}} + \mathcal{N}_{(0,1)}(m_\star, s_\star^2). \quad (27)$$

Если по вокселям латентный гейт распределён как смесь $\alpha \sim \sum_{k=1}^K w_k \mathcal{N}(\mu_k, \sigma_{*,k}^2)$, то маргинальное распределение по маске есть цензурированная гауссова смесь

$$\hat{\alpha} \mid \mathcal{M} \sim p_0 \delta_{\{0\}} + p_1 \delta_{\{1\}} + \sum_{k=1}^K \pi_k \mathcal{N}_{(0,1)}(\mu_k, s_k), \quad s_k^2 = \sigma_{*,k}^2 + \tau^2. \quad (28)$$

Доказательство. Усечение. Оценка $\hat{\alpha} = \text{clip}(\alpha, 0, 1)$ переносит всю вероятностную массу гаусса левее нуля в точку 0 с весом $P(\alpha \leq 0) = \Phi((0 - m_*)/s_*) = \Phi(-m_*/s_*)$ и массу правее единицы в точку 1 с весом $P(\alpha \geq 1) = \Phi((m_* - 1)/s_*)$, оставляя на $(0, 1)$ усечённый гаусс; это (27). *Смесь.* Наблюдаемый гейт есть истинный плюс шум оценки, $\hat{\alpha} = \alpha^* + \eta$ с $\eta \sim \mathcal{N}(0, \tau^2)$, независимым от α^* . Распределение суммы независимых величин есть свёртка их распределений, а свёртка гауссов снова гауссова со сложёнными дисперсиями,

$$\mathcal{N}(\mu_k, \sigma_{*,k}^2) * \mathcal{N}(0, \tau^2) = \mathcal{N}(\mu_k, \sigma_{*,k}^2 + \tau^2),$$

откуда масштабы компонент $s_k^2 = \sigma_{*,k}^2 + \tau^2$; усечение каждой компоненты на $[0, 1]$ порождает граничные массы p_0, p_1 . $\square$

Следствие 8 (Апостериорная вероятность доминирования). Вероятность того, что воксель видео-доминантен, равна

$$P(\alpha > \frac{1}{2} \mid d, r) = 1 - \Phi\left(\frac{\frac{1}{2} - m_*}{s_*}\right). \quad (29)$$

Доказательство. Апостериор гейта есть $\mathcal{N}(m_*, s_*^2)$, поэтому, стандартизуя $Z = (\alpha - m_*)/s_* \sim \mathcal{N}(0, 1)$,

$$P(\alpha > \frac{1}{2} \mid d, r) = P\left(Z > \frac{\frac{1}{2} - m_*}{s_*}\right) = 1 - \Phi\left(\frac{\frac{1}{2} - m_*}{s_*}\right).$$

$\square$

Замечание 2 (Интерпретация ширины распределения). Апостериорная дисперсия τ^2 задаёт шумовой масштаб, относительно которого следует читать наблюдаемый разброс $\hat{\alpha}$. Если оценка внутрипопуляционного разброса $\sigma_{*,k}^2 = s_k^2 - \tau^2$ неотличима от нуля, вся структура распределения (28) объясняется одной лишь неопределённостью оценки гейта, и выделение латентных популяций вокселей статистически не обосновано.

6. Данные и предобработка

6.1. Набор данных

Эксперименты проводятся на открытом наборе данных одновременной регистрации ЭЭГ–фМРТ при просмотре естественного аудиовизуального стимула [17]. Набор содержит записи 30 испытуемых, прошедших фМРТ-сканирование на томографе с индукцией поля 3 Тл. Каждому испытуемому предъявлялся один и тот же короткометражный звуковой фильм длительностью $t = 390$ с, а сопровождающая звуковая дорожка записана с частотой дискретизации 44.1 кГц и синхронизирована с фМРТ-записью по времени. В настоящей работе используется подвыборка из 9 испытуемых. Характеристики записи сведены в Таблицу 1.

Таблица 1: Характеристики набора данных [17].

Величина	Обозначение	Значение
Длительность стимула	t	390 с
Частота кадров видео	ν_v	25 Гц
Частота дискретизации аудио	ν_a	44.1 кГц
Частота снятия фМРТ	μ	1.64 Гц
Размер кадра видео	W, H, C	640, 480, 3
Размер объёма фМРТ	X, Y, Z	40, 64, 64

6.2. Предобработка

Последовательность трёхмерных снимков BOLD-сигнала $S = [s_1, \dots, s_{\mu t}]$ разбивается вдоль временной оси на обучающую и тестовую части в отношении 70/30 без перемешивания, что сохраняет причинно-следственный порядок отсчётов и исключает утечку будущего в обучение. Все статистики предобработки, зависящие от данных, оцениваются только на обучающей части.

Значения вокселей BOLD-объёма нормируются на отрезок $[0, 1]$ процедурой MinMax, настроенной на обучающей части. Для сокращения вычислительной сложности объём предварительно сжимается оператором усредняющего пулинга AvgPool3D с ядром и шагом $c \in \{1, 2, 4, 8\}$, после чего пространственные размеры остаются под прежними обозначениями $X \times Y \times Z$. Маска мозга строится на этой же сжатой сетке (подраздел 6.4), так что усреднение ошибки воксель-в-воксель согласовано с предсказаниями моделей.

Признаки обеих модальностей приводятся к общей временной сетке частотой ν_v линейной интерполяцией по времени, что даёт $n = \nu_v t = 9750$ отсчётов на запись. После передискретизации каждая модальность стандартизируется по каждой размерности (нулевое среднее, единичная дисперсия). Каждому снимку фМРТ с индексом ℓ сопоставляется отсчёт стимула, сдвинутый на гемодинамическую задержку Δt , так что модель предсказывает приращение $\delta_\ell = s_\ell - s_{\ell-1}$ по стимулу, наблюдаемому за Δt секунд до снимка.

6.3. Признаковые представления модальностей

Видео. Каждый кадр кодируется визуальным трансформером ViT-B/16, предобученным на ImageNet [16], с удалённой классификационной головой, так что эмбединг лежит в 768-мерном предклассификационном пространстве. Поток кадров обрабатывается потоково, по одному кадру за раз, что ограничивает пиковую память.

Аудио. Основное представление аудио — 768-мерные покадровые эмбединги HuBERT [15], предобученного самоконтролируемого речевого трансформера. Звуковая волна прогоняется через модель непересекающимися сегментами по 30 с, считывается выход последнего из двенадцати трансформерных слоёв с разрешением порядка 50 Гц. В качестве низкоразмерного базового представления используются 15 мел-частотных кепстральных коэффициентов [31], вычисленных при частоте дискретизации 44.1 кГц и стандартизированных по коэффициентам.

6.4. Маска мозга

Фоновые воксели вне мозга, на которых BOLD-сигнал неинформативен, доминировали бы в усреднённой среднеквадратичной ошибке. Поэтому все ошибки усредняются только по повоксельной маске мозга $\mathcal{M}$, единой для всех сравниваемых моделей. Маска строится в два шага по среднему по времени объёму BOLD на той же сжатой сетке.

На первом шаге временное среднее объёма BOLD $\bar{v}_{ijk}$ пороговируется методом Оцу [33]: порог θ^* выбирается максимизацией межклассовой дисперсии яркостей по гистограмме,

$$\theta^* = \arg \max_{\theta} \omega_0(\theta) \omega_1(\theta) (\mu_0(\theta) - \mu_1(\theta))^2, \quad (30)$$

где ω_0, ω_1 — доли вокселей в двух классах (фон и ткань), а μ_0, μ_1 — их средние яркости; к мозгу относятся воксели с $\bar{v}_{ijk} > \theta^*$. На втором шаге внутри полученной области отсекается нижняя доля q по временной дисперсии, причём пороговый квантиль вычисляется по вокселям, прошедшим первый шаг,

$$\mathcal{M} = \left\{ (i, j, k) : \bar{v}_{ijk} > \theta^* \wedge \text{Var}_t(v_{ijk}^t) > Q_q \right\}, \quad Q_q = \text{quantile}_q(\{\text{Var}_t(v_{ijk}) : \bar{v}_{ijk} > \theta^*\}). \quad (31)$$

Уровень отсечения равен $q = 10^{-3}$ для основной маски (сравнение моделей и распределение гейта) и $q = 0.1$ для повоксельных карт по испытуемым. Одна и та же маска применяется ко всем трём оцениваемым моделям.

7. Вычислительный эксперимент

В этом разделе одномодальная модель из раздела 4 проверяется эмпирически, по схеме экспериментов исходной аудио-работы [34]. Набор данных, разбиение выборки, нормировка и маска мозга описаны в разделе 6; признаками аудиопотока служат мел-частотные кепстральные коэффициенты (раздел 6.3), веса оцениваются методом наименьших квадратов (6) независимо в каждом вокселе, а качество измеряется среднеквадратичной ошибкой (MSE) приращений, усреднённой по маске мозга (31). Проверяются три вопроса: насколько точно модель восстанавливает фМРТ-снимки, как распределены обученные веса и какова гемодинамическая задержка Δt у каждого испытуемого.

7.1. Качество восстановления

Для каждого испытуемого по обученной модели предсказываются приращения BOLD-сигнала на тестовой части и собираются обратно в трёхмерные объёмы. На рисунках 1- 3 для репрезентативных испытуемых приведены срезы истинного объёма, предсказания и их поэлементной разности: предсказание воспроизводит крупномасштабную пространственную структуру отклика, а разность не содержит выраженной анатомической структуры и сосредоточена на уровне шума.




Рис. 1: На рисунке представлены фрагменты из тестового образца, на которых показаны как исходные, так и реконструированные фМРТ изображения, а также их различия. Снимки принадлежат 7 участнику.




Рис. 2: Снимки принадлежат 22 участнику.




Рис. 3: Снимки принадлежат 31 участнику.

Поскольку воксели нормированы на отрезок $[0,1]$ (раздел 6.2), ошибка измеряется в той же шкале. Повоксельная MSE по испытуемым сведена в Таблицу 2; значения порядка 10^{-5} отвечают отклонению в доли процента от динамического диапазона сигнала, что подтверждает состоятельность линейной аппроксимации.

Таблица 2: В таблице приведена среднеквадратичная ошибка (MSE) каждого участника. Поскольку все воксели были нормализованы к $[0,1]$, алгоритм показывает довольно хорошие результаты.

	7й участник	22й участник	31й участник
MSE	$6.39 \cdot 10^{-5}$	$7.46 \cdot 10^{-5}$	$9.00 \cdot 10^{-5}$

7.2. Анализ весов

Чтобы проверить, что модель опирается на широкий набор признаков, а не вырождается к нескольким, исследуется распределение компонент обученного вектора весов (рисунок 4). Гистограмма не имеет выраженного пика и не сконцентрирована вокруг нуля: веса распределены по всей оси примерно равномерно. Это указывает на невырожденность оценки — модель использует разнообразные признаки аудиопотока и обобщается по ним, а не запоминает отдельную компоненту.




Рис. 4: Распределение компонентов вектора весов. Распределение весов модели не показывает концентрации вокруг какого-либо одного значения, отражая невырожденный разброс. Это означает, что модель была хорошо обучена и учитывает широкий спектр характеристик.

7.3. Оценка задержки Δt

Гемодинамическая задержка подбирается перебором по сетке Δt согласно (7), отдельно для каждого испытуемого. На рисунках 5-7 показана зависимость MSE от Δt . При усреднении ошибки по всему объёму мозга кривая зашумлена и обнаруживает несколько локальных минимумов: фоновые и неинформативные воксели маскируют истинный отклик. После ограничения усреднения на область, ответственную за восприятие звука (слуховую кору), на кривой проявляется единственный глобальный минимум, положение которого и берётся как оценка $\widehat{\Delta t}$. Полученные значения задержки лежат в физиологически правдоподобном диапазоне и согласуются с известной инерционностью гемодинамического отклика.




Рис. 5: На рисунке слева показана зависимость среднеквадратичной ошибки (MSE) от времени задержки, при которой наблюдаются два глобальных минимума. Отсутствие четкого минимума говорит о том, что на вычисление MSE по всему фМРТ-изображению влияет шум, потенциально маскирующий истинный базовый сигнал. Чтобы исправить это, MSE был пересчитан с учетом области, которая отвечает за восприятие звука. Представленные результаты были получены на основе данных 7-го участника




Рис. 6: При анализе данных 22-го участника кривая нескорректированной среднеквадратичной ошибки (MSE) показала множественные локальные минимумы, что указывает на наличие шума. После применения коррекции был обнаружен только один глобальный минимум.




Рис. 7: На обоих изображениях показан единый глобальный минимум, но после внесения исправлений на графике было показано заметное уменьшение шума. Представленные результаты были получены на основе данных 31-го участника

7.4. Мультимодальная banded-ridge регрессия

Здесь эмпирически проверяется мультимодальная banded-ridge модель из раздела 5.2, то есть совместная регрессия на склеенных признаках $[X_v \mid X_a]$ с отдельной регуляризацией λ_v и λ_a по модальностям. Она сравнивается с одномодальным аудиобазлайном, поскольку именно аудио задаёт основную предсказательную силу. Аудиопризнаки — это 15 MFCC, видеопризнаки — эмбединги ViT-B/16, сжатые методом главных компонент. Разбиение выборки, нормировка, маска мозга и метрика MSE берутся теми же, что и в разделе 7, чтобы результаты были сопоставимы. Подробный анализ проводится на испытуемом 22, после чего выводы проверяются на нескольких испытуемых. Главный вопрос всего раздела в том, добавляет ли видео предсказательную силу к аудио, и если да, то где именно.

Базовые модели. Одномодальные модели задают точку отсчёта (Таблица 3). Аудиомодель даёт $MSE\ 2.895 \cdot 10^{-5}$ и служит базлайном, который мультимодальная модель должна превзойти. Видеомодель сама по себе достигает примерно такой же ошибки $2.895 \cdot 10^{-5}$, причём ни при каком уровне регуляризации не опускается ниже аудиобазлайна. Это значит, что видео почти не помогает предсказывать приращение BOLD-сигнала, и основная информация о нём сосредоточена в аудио. Более того, при наивном выборе коэффициентов совместная модель оказывается даже хуже аудио ($2.904 \cdot 10^{-5}$), поскольку слабо регуляризованный видеоблок подмешивает шум вместо полезного сигнала. Именно поэтому видео и аудио нельзя штрафовать одинаково, и коэффициенты λ_v и λ_a приходится подбирать отдельно.

Подбор поблочной регуляризации. Главное преимущество banded ridge перед обычной гребневой регрессией состоит в том, что модальности можно штрафовать по-разному, и этот раздел проверяет, удаётся ли так извлечь из видео пользу. Коэффициенты λ_v и λ_a подбираются полным перебором по сетке, в которой λ_v принимает значения от 10^2 до 10^5 , а λ_a — от 10^2 до 10^4 , всего 35 комбинаций. Минимум ошибки достигается при $\lambda_v = 10^3$ и

Таблица 3: Базовые модели на испытуемом 22 ($\Delta t = 3$). Видео само по себе не улучшает аудиобазлайн, наивная совместная модель его ухудшает.

Модель	MSE
Аудио (MFCC, 15)	$2.895 \cdot 10^{-5}$
Видео (ViT, PCA=15)	$2.895 \cdot 10^{-5}$
Banded ridge, наивные λ	$2.904 \cdot 10^{-5}$

$\lambda_a = 10^4$ и составляет $2.894 \cdot 10^{-5}$, лишь незначительно ниже аудиобазлайна $2.895 \cdot 10^{-5}$. При этом аудиоблок штрафует сильнее видеоблока, а разброс ошибки по всей сетке невелик и проявляется только в четвёртой значащей цифре, так что сам выигрыш мал. Принципиально здесь то, что его даёт именно раздельность штрафов. Если задать единый коэффициент на обе модальности и тем самым свести модель к обычному ridge на склеенных признаках, совместная модель уже не превосходит аудио. Дополнительную проверку даёт оценка вклада каждой модальности внутри обученной модели. Ошибки отдельных блоков оказываются близки (видеоблок $2.894 \cdot 10^{-5}$, аудиоблок $2.896 \cdot 10^{-5}$, совместно $2.894 \cdot 10^{-5}$), а значит видео внутри совместного фита работает наравне с аудио, но заметного суммарного скачка качества не приносит.

Размерность видеопризнаков. Эмбединги ViT-B/16 имеют размерность 768, что несопоставимо с 15-мерным аудио. Если склеить их напрямую, видеоблок задавит аудио числом параметров и переобучится на шуме, поэтому видеопризнаки предварительно сжимаются методом главных компонент, причём PCA применяется только к видео и не затрагивает аудио. Сколько компонент оставлять — вопрос компромисса, и на рисунке 8 показана зависимость MSE совместной модели от их числа. У кривой выраженный минимум около 30 компонент (порядка 70% объяснённой дисперсии), где ошибка опускается чуть ниже аудиобазлайна. При меньшем числе компонент видео теряет выразительность и не дотягивает до базлайна, а при большем (50 и более) ошибка резко растёт, поскольку высокоразмерный видеоблок снова начинает переобучаться и подмешивать шум. Этот минимум и определяет выбор порядка 30 компонент в основной модели.

Гемодинамическая задержка. Гемодинамическая задержка влияет на обе модели одинаково, поэтому её перебор по сетке $0 \dots 20$ с проводится для аудио и совместной модели одновременно (рисунок 9). Кривые ведут себя схоже. До $\Delta t \approx 2$ с ошибка велика, затем резко падает и выходит на пологий участок, а минимума обе модели достигают при одном и том же $\Delta t = 8$ с. Это согласуется с оценкой задержки из раздела 7.3 и показывает, что добавление видео не смещает оптимальную задержку. При $\Delta t = 8$ с аудио даёт $2.808 \cdot 10^{-5}$, а banded ridge — $2.805 \cdot 10^{-5}$, то есть совместная модель выигрывает +0.12% по всему мозгу. Это и есть лучший результат banded ridge на уровне всего мозга, и он остаётся очень небольшим.




Рис. 8: MSE совместной banded-ridge модели в зависимости от числа видеоконпонент PCA (испытуемый 22). Пунктир — аудиобазлайн. Видеоразмерность почти не влияет на качество.

Сравнение по испытуемым. Выигрыш на одном испытуемом мог бы оказаться случайностью, поэтому аудио и banded ridge сравниваются ещё на двух испытуемых помимо основного (рисунок 10, Таблица 4). Относительное изменение MSE составляет -0.08% для испытуемого 07, $+0.03\%$ для 22 и -0.07% для 31. Выигрыш не только мал, но и непостоянен по знаку — для двух испытуемых из трёх добавление видео в среднем по мозгу даже слегка ухудшает прогноз. Ту же картину подтверждает корреляционный анализ. Средний коэффициент корреляции Пирсона между предсказанием и истиной равен 0.139 как для аудио, так и для совместной модели, а доля вокселей с заметной корреляцией ($r > 0.1$) у них практически одинакова (40.5% против 40.4%). Иными словами, усреднённое по всему мозгу видео не помогает, и если эффект и существует, то он локален.

Таблица 4: MSE по испытуемым (аудио против banded ridge) и относительное изменение.

Испытуемый	Аудио	Banded ridge	Δ
07	$2.497 \cdot 10^{-5}$	$2.499 \cdot 10^{-5}$	-0.08%
22	$2.895 \cdot 10^{-5}$	$2.894 \cdot 10^{-5}$	$+0.03\%$
31	$3.246 \cdot 10^{-5}$	$3.248 \cdot 10^{-5}$	-0.07%

Где помогает видео. Близкий к нулю выигрыш по всему мозгу ещё не означает, что видео бесполезно, так как усреднённая по мозгу MSE скрывает внутреннюю структуру эффекта. В одних областях видео улучшает прогноз, в других добавляет шум, и при усреднении эти противоположные вклады взаимно гасятся, давая почти нулевой итог. Чтобы разделить их, для каждого вокселя по отдельности вычисляется разность ошибок аудио и совместной модели при оптимальной задержке $\Delta t = 8$, и положительная разность означает, что в этом вокселе видео помогает. Таких вокселей оказывается 44.9%, то есть почти половина, а их пространственное распределение показано на рисунке 11. Чтобы понять, где именно




Рис. 9: MSE как функция задержки Δt для аудио и совместной модели (испытуемый 22). Минимум обеих кривых — при $\Delta t = 8$ с.




Рис. 10: Аудио против совместной banded-ridge модели по испытуемым. На уровне всего мозга различие в пределах статистического шума.

сосредоточен эффект, воксели сначала группируются по приближённым геометрическим областям интереса (Таблица 5). Картина выходит неоднородной и меняется от -0.22% до $+0.24\%$ по разным областям при $+0.12\%$ в среднем. Однако, эти маски лишь грубо приближают анатомию прямоугольными блоками, поэтому привязку к конкретным зонам мозга следует трактовать осторожно. Более надёжный вывод даёт прямой отбор вокселей, в которых видео помогает сильнее всего, без опоры на анатомические маски (рисунок 12). На лучших 1000 таких вокселях MSE падает с $2.705 \cdot 10^{-4}$ до $2.691 \cdot 10^{-4}$, что соответствует улучшению на $+0.49\%$ — вчетверо больше, чем в среднем по мозгу. В итоге польза видео реальна, но сосредоточена в небольшом подмножестве вокселей, а в остальном мозге оно лишь добавляет шум.




Рис. 11: Повоксельная карта улучшения MSE при добавлении видео (испытуемый 22, $\Delta t = 8$). Тёплые области — где совместная модель точнее аудио.

Таблица 5: Изменение MSE по приближённым геометрическим ROI (испытуемый 22, $\Delta t = 8$). Маски — грубое приближение, привязку к анатомии следует трактовать осторожно.

Область	N вокс.	Δ MSE	Доля улучшенных
Зрительная кора (затылок)	1920	−0.03%	51.4%
Слуховая кора (височная)	880	+0.24%	57.7%
Лобная кора	1920	−0.22%	50.4%
Весь мозг	17790	+0.12%	51.7%

Абляции признаков. Наконец, проверяется, не дадут ли выигрыш альтернативные видео-признаки (Таблица 6). Помимо эмбедингов ViT, рассматриваются два варианта. Первый — набор из шести низкоуровневых покадровых признаков: средняя яркость и её стандартное отклонение (контраст), средние значения каналов R , G , B и энергия движения как средняя покадровая разность пикселей. Хотя такие признаки традиционно связывают с активностью ранней зрительной коры, прогноз они не улучшают (−0.004%), то есть простые покадровые характеристики не несут полезной для BOLD-сигнала информации. Второй вариант учитывает не статичное содержание кадра, а его динамику. К эмбедингу каждого кадра добавляется его временная разность — то есть покомпонентная разность между эмбедингами текущего и предыдущего кадров, $\delta v_\ell = v_\ell - v_{\ell-1}$, своего рода дискретная производная последовательности эмбедингов по времени. Мотивация здесь в том, что целевая величина сама является разностью соседних снимков $\Delta = s_\ell - s_{\ell-1}$, поэтому разность видеопризнаков, по идее, должна была бы точнее отслеживать изменение зрительной сцены и лучше соответствовать изменению BOLD-сигнала. Однако на практике это не просто не помогает, а вредит (−0.375%). Причина в том, что разность высокоразмерных эмбедингов между соседними кадрами почти целиком состоит из высокочастотного шума, и модель подмешивает его в прогноз вместо полезного сигнала. Таким образом, ни один из дополнительных признаков не превосходит базовый banded ridge, и лучшая конфигурация (аудио вместе с ViT и низкоуровневыми признаками) даёт те же +0.13%, что и модель только с ViT.




Рис. 12: 1000 вокселей, где видео помогает сильнее всего (красная подсветка), на трёх срезах. На этом подмножестве совместная модель даёт +0.49% к аудио.

Таблица 6: Абляции видеопризнаков (испытуемый 22, $\Delta t = 8$); улучшение относительно аудио.

Модель	MSE	vs аудио
Аудио	$2.808 \cdot 10^{-5}$	+0.00%
Аудио + ViT (PCA=15)	$2.805 \cdot 10^{-5}$	+0.12%
Аудио + низкоуровневые	$2.808 \cdot 10^{-5}$	−0.00%
Аудио + ViT + низкоуровневые	$2.805 \cdot 10^{-5}$	+0.13%
Аудио + ViT + временные разности	$2.819 \cdot 10^{-5}$	−0.38%

Итог. Подведём черту по banded ridge. С отдельной регуляризацией он извлекает из видео лишь небольшое улучшение по всему мозгу, порядка +0.12% при оптимальной задержке, причём непостоянное по знаку между испытуемыми. Само по себе видео почти не предсказывает BOLD-сигнал, а его дополнительные представления, низкоуровневые признаки и временные разности, выигрыша не дают. Вместе с тем эффект не нулевой, а пространственно неоднородный. В большей части мозга видео добавляет шум, но в небольшом подмножестве вокселей заметно помогает, до +0.49%. Ключевая причина слабости banded ridge в том, что он подбирает один общий вес каждой модальности на весь мозг, тогда как полезность видео меняется от вокселя к вокселю. Именно это наблюдение мотивирует следующий шаг — переход от глобального совместного фита к повоксельному отбору модальности, то есть к гейтовой модели раздела 5, где вклад видео и аудио настраивается в каждом вокселе отдельно.

7.5. Гейтовая мультимодальная модель

Здесь оценивается основная модель работы — гейтовая, описанная в разделе 5. В отличие от banded ridge, признаки модальностей не склеиваются и не сжимаются PCA. Полноразмерные эмбединги ViT-B/16 (768 измерений) и аудиоэмбединги HuBERT-base (768 измерений) подаются в две независимые гребневые регрессии, после чего повоксельный скалярный гейт α смешивает их предсказания. Важное отличие от раздела про banded ridge в том, что аудио описывается не 15-мерными MFCC, а 768-мерными эмбедингами HuBERT-base — самообучаемого аудиотрансформера, предобученного на больших речевых корпусах. Если MFCC отражают лишь кратковременный спектральный профиль звука, то HuBERT кодирует более

высокоуровневую фонетическую и контекстную структуру, поэтому аудиопоток становится заметно более информативным. Именно это богатое аудиопредставление задаёт сильный аудиобазлайн, на который гейтовая модель опирается в большинстве вокселей. Таким образом модель сводится к трём замкнутым решениям без нейросетевого обучения, а сам гейт настраивается отдельно в каждом вокселе. Поскольку блоки нормированы и приведены к одному масштабу, коэффициенты регуляризации берутся равными, что является естественным выбором по умолчанию. Качество измеряется как MSE на вокселях маски мозга (порог Оцу по средней интенсивности плюс отсев низкодисперсных вокселей), подробный анализ проводится на испытуемом 22 при задержке $\Delta t = 4$ с, а затем выводы проверяются на девяти испытуемых.

Общее улучшение над одномодальными моделями. Одномодальные регрессии дают близкие ошибки, аудио $1.069 \cdot 10^{-4}$ и видео $1.072 \cdot 10^{-4}$, тогда как гейтовая модель опускается до $9.807 \cdot 10^{-5}$ (Таблица 7). Это соответствует улучшению +8.2% относительно аудио и +8.5% относительно видео. Принципиально, что выигрыш здесь на два порядка больше, чем у banded ridge с его +0.12%, и достигается он именно повоксельным смешиванием, а не глобальной совместной подгонкой. На рисунке 13 цвет кодирует разность ошибок аудио и гейта, где тёплый тон означает, что гейт точнее, а насыщенность — на сколько именно. Холодных (синих) вокселей на карте почти нет, поэтому по доле гейт превосходит аудио в 99.7% вокселей маски, а видео — в 83.6%. Важно, что эти проценты отражают знак разности, а не её величину, и карта показывает, что в большинстве вокселей выигрыш мал (бледные тона), тогда как заметные улучшения сосредоточены в отдельных областях (насыщенно-красные точки). Поэтому суммарные +8% складываются из почти повсеместных, но небольших улучшений и нескольких концентрированных выигрышей, а проигрывает гейт лишь в считанных вокселях.

Таблица 7: Одномодальные модели против гейтовой (испытуемый 22, $\Delta t = 4$, воксели маски мозга).

Модель	MSE	vs аудио
Аудио (HuBERT, 768)	$1.069 \cdot 10^{-4}$	—
Видео (ViT, 768)	$1.072 \cdot 10^{-4}$	−0.3%
Гейтовая модель	$9.807 \cdot 10^{-5}$	+8.2%

Распределение гейта по маске. Гейт α можно прочесть как повоксельный вес видео, где значение около единицы означает опору на видео, а около нуля — на аудио. Внутри маски среднее $\langle \alpha \rangle = 0.258$ при медиане 0.256, причём явно видео-доминантных вокселей ($\alpha > 0.6$) практически нет, а аудио-доминантных ($\alpha < 0.4$) — 96%. Это значит, что гейт повсюду склоняется к аудио, но в большинстве вокселей всё же подмешивает небольшую долю видео. Карта гейта на рисунке 14 подтверждает картину, она почти целиком сине-белая (аудио и смешанные воксели) без красных видео-доминантных зон. Сама гистограмма α по




Рис. 13: Повоксельная разность ошибок аудио и гейтовой модели (испытуемый 22, $\Delta t = 4$). Тёплые области — где гейт точнее аудио, насыщенность отражает величину разности. По знаку гейт выигрывает в 99.7% вокселей маски, но в большинстве из них выигрыш невелик.

маске (рисунок 15) одновершинна и целиком лежит ниже порога доминирования $\alpha = 1/2$, что отражает повсеместное преобладание аудио.




Рис. 14: Повоксельный гейт α на анатомии BOLD (испытуемый 22). Красный — видео ($\alpha \rightarrow 1$), синий — аудио ($\alpha \rightarrow 0$). Видео-доминантных областей нет.

Сравнение по испытуемым. Чтобы убедиться, что выигрыш устойчив, та же схема прогоняется на девяти испытуемых (рисунок 16, Таблица 8). В отличие от banded ridge, который менял знак улучшения от испытуемого к испытуемому, гейтовая модель превосходит аудио у всех девяти, причём улучшение составляет от +7.5% до +13.7%. Средний вес видео по маске держится в диапазоне $0.18 \dots 0.39$, то есть гейт стабильно отдаёт предпочтение аудио, но всюду оставляет видео заметную долю. Дополнительно перебор задержки Δt подтверждает, что относительный порядок трёх моделей сохраняется по всему диапазону задержек.

Аппроксимация распределения гейта. Вероятностная модель раздела 5 предсказывает, что распределение гейта по маске должно иметь форму цензурированного гауссова распределения, поскольку гейт обладает гауссовым апостериором и при этом ограничен отрезком $[0,1]$, на границах которого могут возникать точечные массы. Эмпирическое распределение




Рис. 15: Распределение гейта α по вокселям маски мозга $\cap$ уверенности (испытуемый 22, $n = 1242$). Пунктир — порог доминирования $\alpha = 1/2$, все воксели лежат левее него.




Рис. 16: Аудио, видео и гейтовая модель по испытуемым. Гейтовая модель ниже обеих одномодальных у всех испытуемых.

α действительно одновершинно и сосредоточено около 0.25 (рисунок 17), что согласуется с этим предсказанием. Чтобы проверить форму, не навязывая заранее одну компоненту, к данным подгоняется более гибкая цензурированная гауссова смесь из двух компонент. Она ложится на гистограмму тесно, поскольку статистика Колмогорова–Смирнова $D = 0.010$ и расстояние Вассерштейна $W_1 = 0.001$ заметно ниже эвристических порогов $D < 0.05$ и $W_1 < 0.01$, принятых в самом расчёте за признак тесной подгонки. Подгонка при этом выявляет лёгкую правую асимметрию, поскольку основная компонента (вес $\pi = 0.67$, центр $\mu = 0.22$) описывает главный пик, а вторая, более широкая (вес $\pi = 0.33$, центр $\mu = 0.30$), добавляет небольшое правое плечо. Скоплений у границ нет, на $\alpha = 0$ сидит лишь крошечная масса $p_0 = 0.002$, а на $\alpha = 1$ её нет вовсе, то есть гейт почти никогда не схлопывается полностью к одной модальности. Таким образом, по своим главным чертам — единственная мода, расположение около 0.25, узкий масштаб и отсутствие краевых масс — эмпирическое распределение согласуется с предсказанным теорией цензурированным гауссовым, а вторая

Таблица 8: Улучшение гейтовой модели над одномодальными по испытуемым и средний вес видео $\langle \alpha \rangle$ по маске.

Испытуемый	vs аудио	vs видео	$\langle \alpha \rangle$
04	+7.7%	+5.5%	0.20
07	+8.3%	+6.2%	0.23
09	+8.5%	+4.1%	0.23
11	+8.1%	+6.3%	0.22
14	+13.7%	+9.5%	0.39
15	+7.5%	+0.1%	0.18
16	+11.0%	+5.8%	0.23
22	+8.3%	+9.2%	0.26
31	+9.1%	+3.2%	0.24

компонента смеси лишь улавливает слабую асимметрию, которую одногауссова модель не описывает.




Рис. 17: Распределение гейта α по вокселям маски и его аппроксимация двухкомпонентной цензурированной гауссовой смесью (испытуемый 22). Две гауссовы компоненты с центрами 0.22 и 0.30 плюс точечная масса $p_0 = 0.002$ при $\alpha = 0$. Согласие тесное, $D = 0.010$ и $W_1 = 0.001$.

Предсказание распределения из теории. Предыдущая аппроксимация подбирала смесь под данные, тогда как более строгая проверка — предсказать распределение гейта по выведенным формулам, вычислив шумовой масштаб τ независимо от самой гистограммы, и посмотреть, описывает ли теоретическая кривая эмпирические данные. По следствию 7 наблюдаемая повоксельная оценка есть истинный гейт плюс независимый шум оценивания, $\hat{\alpha} = \alpha^* + \eta$ с $\eta \sim \mathcal{N}(0, \tau^2)$, и в общем виде распределение по маске есть цензурированная гауссова смесь (28) с масштабами компонент $s_k^2 = \sigma_{*,k}^2 + \tau^2$. В случае одной популяции вокселей она сводится к усечённому гауссу $\mathcal{N}(\tilde{\alpha}, \sigma_*^2 + \tau^2)$ с пренебрежимо малыми краевыми массами, где $\tilde{\alpha}$ — средний гейт, σ_* — разброс истинных значений по вокселям, а τ — повоксельная стандартная ошибка оценки. Эта ошибка берётся из формулы дисперсии (24), а для разностной цели $\Delta = s_\ell - s_{\ell-1}$ — из её МА(1)-варианта (26), поскольку остатки автокоррелированы на

лаге 1. Поправка поднимает τ с 0.076 до 0.078, после чего оценка выходит на плато (левая панель рисунка 18). С $\tau = 0.078$ и $\sigma_* = 0.024$ теоретическая кривая ложится на гистограмму тесно, $D = 0.011$ и $W_1 = 0.002$ (правая панель). Более того, в духе замечания 2 разложение $s^2 = \sigma_*^2 + \tau^2$ показывает, что независимо вычисленный шум оценивания τ^2 объясняет 91% наблюдаемого разброса α , а истинный разброс σ_* мал. Это значит, что повоксельная вариация гейта почти целиком является шумом оценивания, а сам гейт по мозгу почти постоянен, что и оправдывает сведение смеси к одной компоненте.




Рис. 18: Предсказание распределения гейта из теории без подгонки (испытуемый 22). Слева — повоксельная стандартная ошибка τ как функция числа учтённых лагов автокорреляции, плато после лага 1. Справа — предсказанная теорией кривая $\mathcal{N}(\tilde{\alpha}, \sigma_*^2 + \tau^2)$ с $\tau = 0.078$ и $\sigma_* = 0.024$, наложенная на эмпирическую гистограмму, $D = 0.011$ и $W_1 = 0.002$.

Карта доминирования модальности. Этот эксперимент напрямую сопоставляет наблюдаемую оценку гейта с предсказанием модели. Рисунок 19 состоит из двух рядов, и сверху показана эмпирическая карта точечной оценки α по вокселям, а снизу — предсказанная моделью вероятность видео-доминирования $P(\alpha > 1/2)$, вычисленная из гауссова апостериора гейта с учётом повоксельной погрешности оценки. Тем самым сравнивается то, что даёт сырая оценка, с тем, что предсказывает теория, когда неопределённость учтена честно. Точечная оценка варьируется по мозгу, однако ни в одном вокселе не дотягивает до порога $1/2$, и теоретическая карта вероятностей это подтверждает и уточняет, поскольку 92% вокселей оказываются уверенно аудио-доминантными ($P < 0.05$), уверенно видео-доминантных нет вовсе, а оставшиеся 8% остаются неопределёнными. Таким образом, предсказание модели совпадает с наблюдаемой картиной, и обе говорят, что надёжно видео-доминантных вокселей не существует, что ещё раз подчёркивает слабый и распределённый характер видеосигнала.

Статистическая значимость. Преимущество гейтовой модели проверяется непараметрическими тестами на девяти испытуемых, поскольку выборка мала и нормальность не предполагается. Критерий Фридмана для трёх связанных моделей отвергает гипотезу об их равенстве, $\chi^2(2) = 16.22$ при $p = 0.0003$, то есть различие между аудио, видео и гейтом не случайно. Затем гейт сравнивается с каждым базлайном по одностороннему критерию

знаковых рангов Уилкоксона для связанных выборок с гипотезой о том, что ошибка гейта меньше. В обеих парах гейт точнее базлайна у всех девяти испытуемых, поэтому статистика принимает минимально возможное значение $W = 0$, а p -значение упирается в нижний предел для $n = 9$, $p_{\text{raw}} = 0.0020$. После поправки Холма на семейство из двух сравнений $p_{\text{Holm}} = 0.0039$ в обоих случаях (Таблица 9). Таким образом, обе нулевые гипотезы отвергаются, а средний относительный выигрыш составляет около +9.1% над аудио и +5.6% над видео, то есть эффект и значим, и велик.

Таблица 9: Статистическая значимость превосходства гейтовой модели над одномодальными (девять испытуемых, односторонний критерий знаковых рангов Уилкоксона с поправкой Холма на два сравнения).

Сравнение	W	p_{Holm}	средний ΔMSE
Гейт против аудио	0	0.0039	+9.1%
Гейт против видео	0	0.0039	+5.6%




Рис. 19: Карта доминирования $P(\alpha > 1/2)$ (испытуемый 22). Сверху точечная оценка α , снизу вероятность видео-доминирования с учётом шума. Уверенно аудио 92%, уверенно видео 0%, неопределённо 8%.

Итог. Гейтовая модель решает задачу, на которой споткнулся banded ridge. Повоксельный отбор модальности даёт реальное и устойчивое улучшение над аудио на всех девяти испытуемых, в среднем около +9%, тогда как глобальная совместная подгонка приносила

лишь около $+0.1\%$ с непостоянным знаком. Это превосходство не случайно, поскольку критерий Фридмана отвергает равенство трёх моделей ($p = 0.0003$), а односторонний критерий Уилкоксона с поправкой Холма подтверждает преимущество гейта над обоими базлайнами ($p_{\text{Holm}} = 0.0039$) при большом размере эффекта. Гейт всюду предпочитает аудио, а вклад видео остаётся слабым и распределённым, и ни один воксель не оказывается надёжно видеодоминантным. Вероятностная сторона модели также подтверждается, так как эмпирическое распределение гейта в основном согласуется с теоретически выведенным цензурированным гауссовым (лишь с лёгкой правой асимметрией), а предсказанная прямо из формул кривая ложится на данные без подгонки. Более того, разложение дисперсии показывает, что почти весь наблюдаемый разброс гейта объясняется шумом оценивания, то есть истинный гейт по мозгу почти постоянен. Ключевое преимущество гейта в том, что он включает видео там, где оно помогает, и подавляет его в остальном мозге, и именно поэтому ему удаётся извлечь из слабого распределённого видеосигнала пользу, недоступную глобальной модели.

8. Заключение

В работе рассмотрена задача мультимодального прогнозирования приращений BOLD-сигнала по аудио- и видеопотоку естественного фильма. Основным результатом является вероятностная модель мультимодального гейта, в которой предсказание каждой модальности получается отдельной байесовской регрессией, а их повоксельная выпуклая комбинация управляется скалярным гейтом α . Для этой модели доказано, что гейтовая оценка есть ортогональная проекция приращения на прямую между предсказаниями модальностей и потому не уступает ни одной из них (Теорема 1), выведен гауссов апостериор гейта (Лемма 3) и получено распределение гейта по маске в виде цензурированной гауссовой смеси с поправкой MA(1) на разностную природу цели (раздел 5.6).

Эмпирическая часть сравнивает два мультимодальных подхода. Совместная регрессия *banded ridge*, штрафующая модальности отдельно, извлекает из видео лишь незначительное улучшение порядка +0.12% по всему мозгу, причём непостоянное по знаку между испытуемыми, а польза видео оказывается сосредоточена в небольшом подмножестве вокселей (до +0.49% на лучших 1000). Гейтовая модель, напротив, даёт реальное и устойчивое улучшение над аудио на всех девяти испытуемых, в среднем около +9%. Это превосходство статистически значимо, поскольку критерий Фридмана отвергает равенство моделей ($p = 0.0003$), а односторонний критерий Уилкоксона с поправкой Холма подтверждает преимущество гейта над обоими одномодальными базлайнами ($p_{\text{Holm}} = 0.0039$) при большом размере эффекта.

Анализ самого гейта показал, что он всюду предпочитает аудио, оставляя видео вес заметно ниже половины, а с учётом неопределённости оценки ни один воксель не оказывается надёжно видео-доминантным. Эмпирическое распределение гейта согласуется с теоретически выведенным цензурированным гауссовым, причём предсказанная прямо из формул кривая ложится на данные без подгонки. Более того, разложение дисперсии показывает, что почти весь наблюдаемый разброс гейта, около 91%, объясняется шумом оценивания, то есть истинный гейт по мозгу почти постоянен, а видеосигнал слаб и распределён.

Таким образом, ключевой вывод работы состоит в том, что повоксельный отбор модальности решает задачу, на которой споткнулась глобальная совместная подгонка. Гейт включает видео там, где оно действительно помогает, и подавляет его в остальном мозге, и именно эта адаптивность позволяет извлечь из слабого видеосигнала пользу, недоступную моделям с единым весом модальности на весь мозг.

Вместе с тем результаты очерчивают и границы подхода. Вклад видео остаётся слабым, а основная предсказательная сила сосредоточена в аудио, поэтому дальнейший рост качества упирается прежде всего в видеопризнаки, так как текущие эмбединги ViT, по-видимому, плохо передают релевантную для BOLD-сигнала информацию о зрительной сцене. Естественными направлениями продолжения являются более выразительные видеопредставления, нелинейные или обучаемые формы гейта, проверка на большем числе испытуемых и наборов данных, а также привязка эффекта к анатомическим областям интереса вместо использованных приближённых геометрических масок.

Список литературы

1. Glover Gary H. Overview of Functional Magnetic Resonance Imaging // *Neurosurgery Clinics of North America*. — 2011. — Vol. 22, no. 2. — Pp. 133–139.
2. Brain Magnetic Resonance Imaging with Contrast Dependent on Blood Oxygenation / Seiji Ogawa, Tso-Ming Lee, Alan R. Kay, David W. Tank // *Proceedings of the National Academy of Sciences*. — 1990. — Vol. 87, no. 24. — Pp. 9868–9872.
3. Bharath Rose Dawn. Functional MRI: Genesis, State of the Art and the Sequel // *Indian Journal of Radiology and Imaging*. — 2014. — Vol. 24, no. 1. — Pp. 6–12.
4. Reconstructing the Spectrotemporal Modulations of Real-Life Sounds from fMRI Response Patterns / Roberta Santoro, Michelle Moerel, Federico De Martino et al. // *Proceedings of the National Academy of Sciences*. — 2017. — Vol. 114, no. 18. — Pp. 4799–4804.
5. Zhao Mingqian, Liu Baolin. An fMRI-Based Auditory Decoding Framework Combined with Convolutional Neural Network for Predicting the Semantics of Real-Life Sounds from Brain Activity // *Applied Intelligence*. — 2025. — Vol. 55. — P. 118. — Article number 118; опубликовано онлайн 10.12.2024.
6. Decoding fMRI Data with Support Vector Machines and Deep Neural Networks / Yun Liang, Ke Bo, Sreenivasan Meyyappan, Mingzhou Ding // *Journal of Neuroscience Methods*. — 2024. — Vol. 401. — P. 110004.
7. Encoding and Decoding in fMRI / Thomas Naselaris, Kendrick N. Kay, Shinji Nishimoto, Jack L. Gallant // *NeuroImage*. — 2011. — Vol. 56, no. 2. — Pp. 400–410.
8. Natural Speech Reveals the Semantic Maps That Tile Human Cerebral Cortex / Alexander G. Huth, Wendy A. de Heer, Thomas L. Griffiths et al. // *Nature*. — 2016. — Vol. 532, no. 7600. — Pp. 453–458.
9. Forecasting fMRI Images from Video Sequences: Linear Model Analysis / Daniil Dorin, Nikita Kiselev, Andrey Grabovoy, Vadim Strijov // *Health Information Science and Systems*. — 2024. — Vol. 12, no. 1. — P. 55.
10. The Continuing Challenge of Understanding and Modeling Hemodynamic Variation in fMRI / Daniel A. Handwerker, Javier Gonzalez-Castillo, Mark D’Esposito, Peter A. Bandettini // *NeuroImage*. — 2012. — Vol. 62, no. 2. — Pp. 1017–1023.
11. Time Course EPI of Human Brain Function during Task Activation / Peter A. Bandettini, Eric C. Wong, R. Scott Hinks et al. // *Magnetic Resonance in Medicine*. — 1992. — Vol. 25, no. 2. — Pp. 390–397.
12. Methods to Detect, Characterize, and Remove Motion Artifact in Resting State fMRI / Jonathan D. Power, Anish Mitra, Timothy O. Laumann et al. // *NeuroImage*. — 2014. — Vol. 84. — Pp. 320–341.

13. *Bright Molly G., Murphy Kevin.* Is fMRI “Noise” Really Noise? Resting State Nuisance Regressors Remove Variance with Network Structure // *NeuroImage*. — 2015. — Vol. 114. — Pp. 158–169.
14. *Nunez-Elizalde Anwar O., Huth Alexander G., Gallant Jack L.* Voxelwise Encoding Models with Non-Spherical Multivariate Normal Priors // *NeuroImage*. — 2019. — Vol. 197. — Pp. 482–492.
15. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units / Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai et al. // *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. — 2021. — Vol. 29. — Pp. 3451–3460.
16. An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale / Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov et al. // International Conference on Learning Representations (ICLR). — 2021.
17. Open Multimodal iEEG–fMRI Dataset from Naturalistic Stimulation with a Short Audiovisual Film / Julia Berezutskaya, Mariska J. Vansteensel, Erik J. Aarnoutse et al. // *Scientific Data*. — 2022. — Vol. 9, no. 1. — P. 91.
18. *Demšar Janez.* Statistical Comparisons of Classifiers over Multiple Data Sets // *Journal of Machine Learning Research*. — 2006. — Vol. 7. — Pp. 1–30.
19. *Raichle Marcus E.* The Brain’s Dark Energy // *Scientific American*. — 2010. — Vol. 302, no. 3. — Pp. 44–49. — Существует также версия в Science 314(5803):1249–1250, 2006 (doi:10.1126/science.1134405) — при необходимости можно сослаться на неё.
20. Predicting Human Resting-State Functional Connectivity from Structural Connectivity / Christopher J. Honey, Olaf Sporns, Leila Cammoun et al. // *Proceedings of the National Academy of Sciences*. — 2009. — Vol. 106, no. 6. — Pp. 2035–2040.
21. Towards a New Approach to Reveal Dynamical Organization of the Brain Using Topological Data Analysis / Manish Saggar, Olaf Sporns, Javier Gonzalez-Castillo et al. // *Nature Communications*. — 2018. — Vol. 9. — P. 1399.
22. Uncovering the Topology of Time-Varying fMRI Data Using Cubical Persistence / Bastian Rieck, Tristan Yates, Christian Bock et al. // Advances in Neural Information Processing Systems (NeurIPS). — Vol. 33. — 2020. — Pp. 6900–6912.
23. A Task-Optimized Neural Network Replicates Human Auditory Behavior, Predicts Brain Responses, and Reveals a Cortical Processing Hierarchy / Alexander J. E. Kell, Daniel L. K. Yamins, Erica N. Shook et al. // *Neuron*. — 2018. — Vol. 98, no. 3. — Pp. 630–644.
24. *Penny William D., Trujillo-Barreto Nelson J., Friston Karl J.* Bayesian fMRI Time Series Analysis with Spatial Priors // *NeuroImage*. — 2005. — Vol. 24, no. 2. — Pp. 350–362.

25. *Eklund Anders, Lindquist Martin A., Villani Mattias.* A Bayesian Heteroscedastic GLM with Application to fMRI Data with Motion Spikes // *NeuroImage*. — 2017. — Vol. 155. — Pp. 354–369.
26. *Moerel Michelle, De Martino Federico, Formisano Elia.* An Anatomical and Functional Topography of Human Auditory Cortical Areas // *Frontiers in Neuroscience*. — 2014. — Vol. 8. — P. 225.
27. *Humphries Colin, Liebenthal Einat, Binder Jeffrey R.* Tonotopic Organization of Human Auditory Cortex // *NeuroImage*. — 2010. — Vol. 50, no. 3. — Pp. 1202–1211.
28. Encoding of Natural Sounds at Multiple Spectral and Temporal Resolutions in the Human Auditory Cortex / Roberta Santoro, Michelle Moerel, Federico De Martino et al. // *PLoS Computational Biology*. — 2014. — Vol. 10, no. 1. — P. e1003412.
29. Using High Spatial Resolution fMRI to Understand Representation in the Auditory Network / Michelle Moerel, Essa Yacoub, Omer Faruk Gulban et al. // *Progress in Neurobiology*. — 2021. — Vol. 207. — P. 101887.
30. *Talavage Thomas M., Gonzalez-Castillo Javier, Scott Sophie K.* Auditory Neuroimaging with fMRI and PET // *Hearing Research*. — 2014. — Vol. 307. — Pp. 4–15.
31. *Davis Steven B., Mermelstein Paul.* Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences // *IEEE Transactions on Acoustics, Speech, and Signal Processing*. — 1980. — Vol. 28, no. 4. — Pp. 357–366.
32. *Abdul Zrar Kh., Al-Talabani Abdulbasit K.* Mel Frequency Cepstral Coefficient and Its Applications: A Review // *IEEE Access*. — 2022. — Vol. 10. — Pp. 122136–122158.
33. *Otsu Nobuyuki.* A Threshold Selection Method from Gray-Level Histograms // *IEEE Transactions on Systems, Man, and Cybernetics*. — 1979. — Vol. 9, no. 1. — Pp. 62–66.
34. *Ivanova Anna, Dorin Daniil, Grabovoy Andrey.* Approximation of fMRI Data from the Audio Time Series. — Preprint, under review.