

Мультимодальная аппроксимация данных фМРТ на основе аудиовизуальных стимулов

Анастасия Яновна Герман

Научный руководитель: к.ф.-м.н. А. В. Грабовой

Научный консультант: Дорин Д.Д.

Кафедра интеллектуальных систем ФПМИ МФТИ

2026

От baseline к gated-модели

Ранее: линейная модель MFCC ($d=15$) $\rightarrow$ BOLD

Ограничения предыдущего подхода:

- ▶ Сильная асимметрия модальностей: видео 768-d vs аудио 15-d
- ▶ Общий вес модальностей для всего мозга
- ▶ Скромный прирост качества (+0.12% от добавления видео)

Гипотеза этой работы

Разные участки мозга по-разному откликаются на видео и аудио. Нужна модель, в которой каждый воксель сам выбирает пропорцию смешивания модальностей.

Gated multimodal модель

Идея. Per-voxel скаляр $\alpha_v \in [0, 1]$ определяет вклад каждой модальности:

$$\hat{\delta}_v(t) = \alpha_v \cdot \hat{\delta}_v^{\text{video}}(t) + (1 - \alpha_v) \cdot \hat{\delta}_v^{\text{audio}}(t) \quad (1)$$

Обучение в три closed-form шага:

1. Ridge по видео: $\mathbf{W}_v = (\mathbf{X}_v^\top \mathbf{X}_v + \lambda_v \mathbf{I})^{-1} \mathbf{X}_v^\top \Delta$
2. Ridge по аудио: $\mathbf{W}_a$ симметрично
3. Для каждого вокселя v :

$$\alpha_v = \arg \min_{\alpha \in [0,1]} \sum_t (\delta_{v,t} - \alpha \hat{\delta}_{v,t}^v - (1 - \alpha) \hat{\delta}_{v,t}^a)^2 \quad (2)$$

- Полностью интерпретируемая модель

Симметричные эмбединги: HuBERT вместо MFCC

Видео: ViT-B/16 покадрово

- ▶ CLS-токен последнего слоя
- ▶ Размерность 768

Аудио: HuBERT-base


- ▶ Self-supervised speech-модель
- ▶ Размерность 768 (вместо 15 у MFCC)
- ▶ Семантически богатое представление

Ключевой эффект

Обе модальности симметричны по размерности и выразительной силе $\Rightarrow$ ridge-задачи одинаковой сложности, α -распределение не смещено архитектурно.

Модальность	dim
Видео (ViT-B/16)	768
Аудио (MFCC, прежде)	15
Аудио (HuBERT, сейчас)	768

Основной результат: 9 испытуемых



- ▶ Gated стабильно ниже обоих бейзлайнов
- ▶ Эффект воспроизводится на всех 9 испытуемых
- ▶ Средняя редукция MSE:
 - ▶ vs Audio: +**8.99%**
 - ▶ vs Video: +**5.10%**


Статистическая значимость результатов

1. **Критерий Фридмана** (3 модели, 9 пациентов): $\chi^2(2) = 16.22$, $p = 0.0003$
 $\Rightarrow$ различия между моделями есть
2. **Критерий знаковых рангов Уилкоксона для связанных выборок**
(одностороннее: $\text{gated} < \text{baseline}$):
обе пары $W = 0$, $p_{\text{raw}} = 0.0020$ (нижний предел при $n=9$)
3. **Метод Холма** на семью из 2 тестов: $p_{\text{Holm}} = 0.0039$

Сравнение	p_{Holm}	$\Delta\text{MSE, \%}$
Gated vs Audio	0.0039	+8.99
Gated vs Video	0.0039	+5.10

$\Rightarrow$ Обе H_0 отвергнуты, эффект большой.

Распределение α : CGMM-модель



Censored Gaussian Mixture:

$$p(\alpha) = p_0 \delta(\alpha) + p_1 \delta(\alpha - 1) + \\ + (1 - p_0 - p_1) \sum_{k=1}^2 \pi_k \mathcal{N}_{(0,1)}^{(k)}$$

Выводы

- ▶ Предложена gated multimodal модель с per-voxel α -смешиванием — для каждого вокселя определяется баланс видео и аудио
- ▶ Переход на симметричные эмбединги (HuBERT + ViT, по 768-d) устраняет архитектурный перекос модальностей
- ▶ Получен статистически значимый прирост над обоими бейзлайнами: +8.99% vs аудио, +5.10% vs видео
- ▶ Результат воспроизводится на всех 9 испытуемых
- ▶ Распределение α по мозгу описывается CGMM-моделью с двумя усечёнными нормальями